

پروژه تشخیص سرقت ادبی در برنامه‌نویسی با رویکرد چندسطحی

درس طراحی کامپایلر - نیمسال اول ۱۴۰۵ - دکتر علائیان

گروه ۴

سارینا ناصرمقدسی ۴۰۲۲۲۰۸۳ حنانه احمدی ۴۰۲۴۷۲۱۳


[گیت هاب پروژه: https://github.com/srn-nm/compiler-project](https://github.com/srn-nm/compiler-project)

مقدمه

پروژه «تشخیص سرقت ادبی در برنامه‌نویسی» با هدف طراحی و پیاده‌سازی یک سامانه چندسطحی برای سنجش میزان شباهت میان دو قطعه کد تعریف شده است. این سامانه با تحلیل کدها در سه سطح توکن، درخت نحوی انتزاعی (AST) و گراف جریان کنترل (CFG)، قادر به شناسایی انواع مختلف کپی‌برداری از تغییرات سطحی تا بازنویسی‌های عمیق ساختاری و رفتاری می‌باشد. در این مستند، تمامی اجزای طراحی شده شامل تحلیلگر لغوی، نحوی، گرامرها، الگوریتم‌های تشخیص شباهت و رابط کاربری به تفصیل شرح داده شده است.

معماری کلی سیستم

سامانه از سه فاز اصلی تشکیل شده که به صورت زنجیره‌ای و مکمل عمل می‌کنند. خروجی هر فاز به عنوان ورودی فاز بعدی مورد استفاده قرار می‌گیرد. شکل زیر نمای کلی معماری سیستم را نشان می‌دهد.



- فاز اول: دریافت کد خام، انجام تحلیل لغوی، استخراج توکن‌ها و محاسبه شباهت مبتنی بر توکن.
 - فاز دوم: دریافت کد، ساخت درخت نحوی انترنال، نرمال‌سازی و مقایسه ساختار درخت‌ها.
 - فاز سوم: دریافت AST، ساخت گراف جریان کنترل، اعمال الگوریتم‌های تطبیق گراف و محاسبه شباهت رفتاری.
-

طراحی Lexer تحلیلگر لغوی

تحلیلگر لغوی وظیفه تبدیل رشته کد ورودی به جریانی از توکن‌های معنادار را بر عهده دارد. برای پشتیبانی از زبان‌های مختلف، از **Strategy Pattern** استفاده شده و هر زبان دارای یک هندر اختصاصی است.

ساختار هندرهای زبان

کلاس پایه BaseLanguageHandler در فایل base_handler.py تعریف شده و شامل متدهای انترنال get_normalized_tokens و get_tokens می‌باشد.
همچنین توابع مشترکی مانند normalize_whitespace و preprocess_code در این کلاس پیاده‌سازی شده‌اند.

پیاده‌سازی برای پایتون

از دو روش برای توکن‌سازی استفاده می‌کند:

۱. **ANTLR** : با بهره‌گیری از گرامر Python3Lexer.g4 و کلاس تولید شده، توکن‌ها با دقت بالا استخراج می‌شوند.

۲. روش جایگزین (**Fallback**) : در صورت عدم دسترسی به فایل‌های ANTLR، از عبارت‌های با قاعده برای تشخیص توکن‌ها استفاده می‌شود.

متدهای normalize_identifiers نام شناسه‌ها را به IDENTIFIER تبدیل کرده و متدهای normalize_literals اعداد و رشته‌ها را با برجسبهای STRING و NUMBER جایگزین می‌کند.

پیاده‌سازی برای جاوا و C++

هندرهای CppHandler و JavaHandler نیز به طور مشابه طراحی شده‌اند. برای C++ به دلیل پیچیدگی بیشتر، الگوهای regex تخصصی‌تری برای شناسایی هدرها، عملگرهای ترکیبی و کامنت‌های چندخطی تعییه شده است.

پیش‌پردازش و نرمال‌سازی

تمامی هندرها کد ورودی را پیش از توکن‌سازی، مطابق تنظیمات پیکربندی (config.json) پردازش می‌کنند:

- حذف کامنت‌ها با توجه به نحوه زبان
- نرمال‌سازی فاصله‌ها تبدیل چند فاصله به یک فاصله، حذف خطوط خالی
- یکسان‌سازی حروف در صورت غیر حساس بودن به بزرگی یا کوچکی حروف
- نرمال‌سازی شناسه‌ها و مقادیر ثابت برای افزایش دقیقت در تشخیص شباهت

طراحی AST و Parser

فاز دوم سامانه، تحلیل ساختاری کدها را بر عهده دارد. هسته این بخش، ساخت درخت نحوی انتزاعی و مقایسه آن‌هاست.

کلاس ASTNode

کلاس ASTNode در analyzer.py نمایش یک گره درخت را بر عهده دارد. هر گره شامل موارد زیر است:

- node_type (FunctionDef, If, Name) نوع گره

- value مقدار (در صورت وجود، مانند نام تابع یا مقدار ثابت)
- children لیست گره‌های فرزند
- line و col موقعیت در کد منبع
- hash هش محاسبه شده از نوع گره و هش فرزندان (برای مقاومت در برابر تغییر نام)
- structural_hash هش تنها بر اساس ساختار و بدون در نظر گرفتن نوع گره

(متدهای `to_dict` ساختار درخت را به صورت دیکشنری بازمی‌گرداند که برای انتقال به فاز سوم (CFG) و ذخیره‌سازی در JSON استفاده می‌شود).

تبدیل کد به AST

در `ASTSimilarityAnalyzer.parse_code` با توجه به زبان ورودی، متدهای مناسب فراخوانی می‌شود. برای پایتون، از ماثول استاندارد `ast` استفاده شده و با پیمایش بازگشتی، شیء `ASTNode` ساخته می‌شود.

```
def parse_python_ast(self, code: str) -> ASTNode:
    tree = ast.parse(code)
    return self.convert_ast_node(tree)
```

همان طور که در بالا مشاهده می‌شود، متدهای `convert_ast_node` و `ast` را به `ASTNode` تبدیل کرده و در صورت فعال بودن گزینه نرم‌السازی، نام‌ها و مقادیر ثابت را تغییر می‌دهد.

نرم‌السازی گره‌ها

- نرم‌السازی شناسه‌ها: تمامی نام متغیرها، توابع و کلاس‌ها به `VAR`, `FUNC`, `CLASS` تبدیل می‌شوند مگر آنکه در لیست استثنایها (`cout`, `print`) باشند.

- نرمال‌سازی مقادیر ثابت: اعداد به NUMBER، رشته‌ها به STRING، بولین‌ها به BOOLEAN و ... تبدیل می‌گردند.

هش ساختاری

- دو نوع هش برای مقاومت در برابر تغییرات سطحی محاسبه می‌شود:
- ترکیب hash: node_type و هش فرزندان → تغییر نوع گره را منعکس می‌کند.
 - تنها هش فرزندان (بدون در نظر گرفتن نوع گره) → برای مقایسه ساختار صرف نظر از برچسب‌ها.
-

گرامرها

برای زبان‌های پایتون، جاوا و C++، از گرامرها رسمی ANTLR استفاده شده است. این گرامرها از مخازن رسمی ANTLR برگرفته و در پوشه grammars/generated قرار گرفته‌اند.

فایل‌های گرامر ANTLR

- Python3Lexer.g4 / Python3Parser.g4
- JavaLexer.g4 / JavaParser.g4
- CPP14Lexer.g4 / CPP14Parser.g4

قوانین Lexer

در هر گرامر، توکن‌های کلیدی، عملگرها، جداول‌نامه‌ها و لیترال‌ها تعریف شده‌اند. به عنوان نمونه، بخشی از گرامر پایتون:

تولید کد از گرامر

با استفاده از ابزار ANTLR، فایل‌های Lexer و Parser به زبان پایتون تولید شده‌اند. دستور نمونه:

```
antlr4 -Dlanguage=Python3 -visitor -o generated/python Python3Lexer.g4  
Python3Parser.g4
```

این فایل‌های تولید شده در مسیر `grammars/generated/python` قرار گرفته و توسط هندرهای مربوطه فراخوانی می‌شوند.

الگوریتم‌های تشخیص شباهت

فاز اول: شباهت مبتنی بر توکن

هدف: تشخیص کپی‌برداری مستقیم و تغییرات جزئی در سطح کد.

مراحل:

۱. توکن‌سازی و نرمال‌سازی کدها توسط هندر زبان.

۲. محاسبه معیارهای شباهت:

• **Jaccard Similarity** بر روی مجموعه توکن‌ها.

• **Cosine Similarity** بردار فراوانی توکن‌ها.

• **Levenshtein Similarity** فاصله ویرایش رشته توکن‌ها.

• **Sequence Similarity** بر اساس طولانی‌ترین زیررشته مشترک.

۳. ترکیب وزن‌دار معیارها (وزن‌های پیش‌فرض: ۰.۲، ۰.۳، ۰.۲، ۰.۳).

۴. استخراج بخش‌های مشابه با الگوریتم تطبیق پنجره‌ای.

۵. ذخیره‌سازی نتایج شامل درصد شباهت، آمار توکن‌ها و بخش‌های مشابه در قالب JSON.

کلاس اصلی: `TokenSimilarityAnalyzer` در `phase1/token_similarity_analyzer.py`

خروجی فاز اول پس از اجرای دستور مقابل:

```
python phase1/src/main.py phase1/tests/test_python/code1.py  
phase1/tests/test_python/code2.py --visual -verbose
```

خروجی:

Detailed Metrics:

Jaccard Similarity : 94.12%
Cosine Similarity : 99.78%
Levenshtein Similarity : 76.13%
Sequence Similarity : 76.63%
Normalized Jaccard : 94.12%

Token Statistics:

File 1: 472 tokens (33 unique types)
File 2: 599 tokens (33 unique types)
Common token types: 32

Most Common Tokens:

File 1: NAME(112), NEWLINE(56), NUMBER(38), OPEN_PAREN(30), CLOSE_PAREN(30)
File 2: NAME(148), NEWLINE(77), NUMBER(42), OPEN_PAREN(38), CLOSE_PAREN(38)


نتایج در فایل‌های زیر ذخیره خواهد شد:

JSON: phase1/results/similarity_report_Phase1.json

HTML: phase1/results/similarity_report_Phase1.html

Text: phase1/results/similarity_report_Phase1.txt

Overall similarity: 87.5%



The figure shows a 'Visual Code Comparison' interface. It displays two side-by-side code editors. The left editor is for 'code1.py' and the right is for 'code2.py'. Both editors show Python code. The code for both files is very similar, reflecting the high similarity score from the report. The code includes functions for calculating Fibonacci sequences, finding prime numbers, and sorting lists using bubble sort.

```
code1.py
code2.py
```

```
def calculate_fibonacci(n):
    """
    Calculate Fibonacci sequence up to n terms
    """
    if n <= 0:
        return []
    elif n == 1:
        return [0]
    elif n == 2:
        return [0, 1]
    else:
        fib_sequence = [0, 1]
        for i in range(2, n):
            next_term = fib_sequence[i-1] + fib_sequence[i-2]
            fib_sequence.append(next_term)
        return fib_sequence

def find_primes(limit):
    # Find all prime numbers up to limit
    primes = []
    for num in range(2, limit + 1):
        is_prime = True
        for i in range(2, int(num**0.5) + 1):
            if num % i == 0:
                is_prime = False
                break
        if is_prime:
            primes.append(num)
    return primes

def sort_list(numbers):
    """Sort a list of numbers in ascending order"""
    n = len(numbers)
    for i in range(n):
        for j in range(i, n-1):
            if numbers[j] > numbers[j+1]:
                numbers[j], numbers[j+1] = numbers[j+1], numbers[j]

def compute_fibonacci(terms):
    """
    Compute Fibonacci numbers for given terms count
    """
    if terms <= 0:
        return []
    elif terms == 1:
        return [0]
    elif terms == 2:
        return [0, 1]
    else:
        result = [0, 1]
        for idx in range(2, terms):
            new_value = result[idx-1] + result[idx-2]
            result.append(new_value)
        return result

def get_prime_numbers(max_value):
    # Generate prime numbers below max_value
    prime_list = []
    for current in range(2, max_value + 1):
        prime_flag = True
        for divisor in range(2, int(current**0.5) + 1):
            if current % divisor == 0:
                prime_flag = False
                break
        if prime_flag:
            prime_list.append(current)
    return prime_list

def bubble_sort(arr):
    """Sort array using bubble sort algorithm"""
    size = len(arr)
    swapped = False
    for i in range(size):
        swapped = False
        for j in range(0, size-i-1):
            if arr[j] > arr[j+1]:
                swapped = True
                arr[j], arr[j+1] = arr[j+1], arr[j]
```

```

51     fib_result = calculate_fibonacci(10)
52     print(f'First 10 Fibonacci numbers: {fib_result}')
53
54     # Test primes
55     prime_result = find_primes(50)
56     print(f'Primes up to 50: {prime_result}')
57
58     # Test sorting
59     numbers_to_sort = [64, 34, 25, 12, 22, 11, 80]
60     sorted_numbers = sorted(numbers_to_sort.copy())
61     print(f'Sorted list: {sorted_numbers}')
62
63     # Test student class
64     student1 = Student("Alice", 20, [85, 90, 78, 92, 88])
65     student1.display_info()

```



```

66     def compute_average_score(self):
67         if len(self.scores) == 0:
68             return 0.0
69         total = 0.0
70         for score in self.scores:
71             total += score
72         return total / len(self.scores)
73
74     def show_details(self):
75         average = self.compute_average_score()
76         print(f'Name: {self.full_name}')
77         print(f'Age: {self.years_old}')
78         print(f'Average Score: {average:.1f}')
79
80     # Driver code
81     if __name__ == "__main__":
82         # Fibonacci sequence
83         fib_output = compute_fibonacci(8)
84         print(f'Fibonacci sequence (# terms): {fib_output}')
85
86         # Prime numbers
87         primes = get_prime_numbers(50)
88         print(f'Prime numbers up to 50: {primes}')
89
90         # Sorting example
91         data = [45, 23, 47, 10, 89, 34, 56]
92         sorted_data = bubble_sort(data.copy())
93         print(f'Original: {data}')
94         print(f'Sorted: {sorted_data}')
95
96         # Student information
97         grades = [88, 92, 76, 95, 84]
98         student = UniversityStudent("Bob", 22, grades)
99         student.show_details()
100
101     # Additional test
102     x = 10
103     y = 20
104     sum_result = x + y
105
106     print(f'Sum of {x} and {y} is {sum_result}')

```

Matching Sections Details

Match 1 13 tokens • Lines 9-12 → Lines 9-12

=> 2 : return [8 , 1]

Match 2 11 tokens • Lines 7-9 → Lines 7-9

=> 1 : return [8]

Match 3 11 tokens • Lines 56-61 → Lines 74-79

) if __name__ == "__main__":

Match 4 10 tokens • Lines 5-7 → Lines 5-7

=> 8 : return [1]

Match 5 10 tokens • Lines 24-25 → Lines 24-25

=> 8.5) + 1) : if

Match 6 9 tokens • Lines 36-37 → Lines 38-39

=> 1 < 1) ; if


Match 7 8 tokens • Lines 12-13 → Lines 12-13

= [8 , 1] : for

Match 8 8 tokens • Lines 26-28 → Lines 26-28

= False break if

Match 9 8 tokens • Lines 37-38 → Lines 39-40



فاز دوم: شباهت مبتنی بر AST

هدف: شناسایی شباهت‌های ساختاری با وجود تغییر نام متغیرها، بازآرایی توابع و تغییرات سطحی.

الگوریتم‌ها:

- .(Jaccard) مقایسه مجموعه هش‌های ساختاری همه گره‌ها : **Structural Similarity** •
- . شباهت کسینوسی توزیع انواع گره. : **Node Type Distribution Similarity** •
- . اشتراک هش زیردرخت‌ها با عمق محدود. : **Subtree Matching Similarity** •
- . شباهت بر اساس اختلاف عمق درخت. : **Tree Depth Similarity** •

نمره نهایی AST: ترکیب وزن‌دار سه معیار اصلی (ساختاری، توزیع نوع، تطبیق زیردرخت).

ذخیره‌سازی AST: خروجی فاز ۲ شامل دیکشنری ast1_dict و ast2_dict است که توسط متدهای to_dict از شیء ASTNode تولید می‌شود. این دیکشنری‌ها در فاز ۳ برای ساخت CFG استفاده می‌گردند.

کلاس اصلی: .phase2/src/analyzer.py در Phase2ASTSimilarity و ASTSimilarityAnalyzer

خروجی با اجرای دستور زیر:

Command line:

```
python -m phase2.src.main --phase1-results  
phase1/results/similarity_report_Phase1.json -f1 phase1/tests/test_python/code1.py -  
f2 phase1/tests/test_python/code2.py
```

Loading Phase 1 results...

Phase 1 results loaded: 87.5% similarity

Phase 1 loaded: 87.5% similarity

- Matching sections: 64
- Common variables: 15

Combined Score: 80.4%

- Token: 87.5%
- AST: 77.4%

AST Metrics:

- Structural: 54.9%
- Node Type: 99.8%
- Subtree: 85.0%

- Depth: 100.0%

Decision:

- Threshold: 65%
- Result: SIMILAR (Possible Plagiarism)


نهایتاً اطلاعات به دست آمده در آدرس‌های زیر ذخیره می‌شوند:

JSON report: phase2/results/phase2_report.json

HTML report saved: phase2/results/phase2_report_integrated.html

Final Similarity Score: 80.4%





فاز سوم: شباهت مبتنی بر CFG

هدف: تحلیل رفتار اجرایی برنامه و تشخیص سرقت‌های پنهان در سطح منطق.

ساخت **AST** از **CFG**

کلاس CFGBuilder با پیمایش دیکشنری AST، گره‌های CFG را ایجاد می‌کند. هر گره دارای نوع (... , ENTRY, EXIT, BASIC_BLOCK, DECISION, LOOP) و لیست یال‌های ورودی/خروجی است.

ساختارهای کنترلی مانند if, for, while به گراف تبدیل می‌شوند.

الگوریتم‌های شباهت گراف:

• **Structural Similarity** مقایسه ویژگی‌های سطح گراف (تعداد گره/یال، درجه، توزیع نوع،

پیچیدگی سیکلوماتیک).

- یافتن بهترین تطبیق بین گره‌ها با ماتریس شباخت و محاسبه هزینه ویرایش.
- استخراج زیرگراف‌های مهم (حول گره‌های تصمیم و حلقه) و مقایسه آن‌ها.
- شباهت مسیرهای اجرایی مبتنی بر LCS.

یکپارچه‌سازی:

کلاس Phase3CFGSimilarity نتایج فازهای ۱ و ۲ را دریافت کرده، AST واقعی را از CFGAnalyzer ارسال می‌کند. سپس نمره CFG را با نمرات قبلی ترکیب می‌کند.

کلاس‌های اصلی:

phase3/analyzer/cfg_analyzer.py در CFGAnalyzer، Phase3CFGSimilarity phase3/analyzer/graph_similarity.py در GraphSimilarity

خروجی:





نتیجه‌گیری

در این پروژه یک سامانه تشخیص سرقت ادبی سه‌سطحی با قابلیت تحلیل توکن، ساختار و رفتار برنامه پیاده‌سازی شد. استفاده از ANTLR برای تحلیل دقیق زبان‌های مختلف و به‌کارگیری الگوریتم‌های پیشرفته تطبیق گراف، دقت تشخیص را نسبت به روش‌های سنتی بهبود می‌بخشد.